

Deteksi Anomali Menggunakan Metode Transformer pada Data Operasional Migas

Tugas Akhir

diajukan untuk memenuhi salah satu syarat memperoleh gelar

sarjana dari Program Studi S1 Sains Data

Fakultas Informatika

Universitas Telkom

1305220072

Steven Immanuel C Girsang



**Universitas
Telkom**

Program Studi Sarjana S1 Sains Data

Fakultas Informatika

Universitas Telkom

Bandung

2026

LEMBAR PENGESAHAN

Deteksi Anomali Menggunakan Metode Transformer pada Data Operasional Migas

Anomaly Detection Using Transformer Method on Oil and Gas Operational Data

1305220072

Steven Immanuel C Girsang

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Program Studi Sarjana S1 Sains Data


Fakultas Informatika

Universitas Telkom

Bandung, 12 Januari 2026

Menyetujui

Pembimbing I,



Dr. Aditya Firman Ihsan, S.Si., M.Si.

NIP: 21950003

Ketua Program Studi
Sarjana S1 Sains Data,



Dr. Gamma Kosala, S.Si.


NIP: 21920013

LEMBAR ORISINALITAS

Dengan ini saya, Steven Immanuel C Girsang, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Deteksi Anomali Menggunakan Metode Transformer pada Data Operasional Migas beserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, 12 Januari 2026

Yang menyatakan



Steven Immanuel C Girsang

NIM 1305220072

ABSTRAK

Industri minyak dan gas (migas) memiliki sistem operasional kompleks yang menghasilkan data historis dari berbagai sensor seperti tekanan, suhu, laju volume, dan laju energi. Deteksi anomali diperlukan untuk mengidentifikasi pola yang menyimpang dari kondisi operasional normal yang berpotensi menunjukkan gangguan sistem. Pendekatan tidak terawasi (unsupervised) dipilih karena data operasional umumnya tidak memiliki label anomali.

Penelitian ini menggunakan metode berbasis deep learning dengan arsitektur Transformer untuk mendeteksi anomali pada data deret waktu multivariat. Tiga model dibandingkan, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer. Dataset yang digunakan merupakan data operasional migas tahun 2017-2021 dengan empat fitur utama: *Pressure*, *Temperature*, *Volume Rate*, dan *Energy Rate*. Data dibagi menjadi 70% pelatihan, 15% validasi, dan 15% pengujian secara temporal.

Setiap model menghasilkan skor anomali berdasarkan error rekonstruksi atau discrepancy dan dibandingkan dengan threshold persentil 90. Hasil penelitian menunjukkan bahwa Transformer Autoencoder mendeteksi anomali paling banyak namun dengan pemisahan skor dan stabilitas terendah. TranAD mendeteksi paling sedikit dengan waktu inferensi terlama. Anomaly Transformer memberikan keseimbangan optimal dengan pemisahan skor tertinggi, stabilitas tertinggi, dan waktu inferensi tercepat melalui mekanisme association discrepancy. Berdasarkan evaluasi sensitivitas, stabilitas, dan efisiensi komputasi, Anomaly Transformer terbukti paling cocok untuk sistem deteksi anomali operasional migas.

Kata Kunci: Deteksi anomali, Transformer, TranAD, Anomaly Transformer, Autoencoder, Deret Waktu Multivariat.

ABSTRACT

The oil and gas industry has complex operational systems that generate historical data from various sensors such as pressure, temperature, volume rate, and energy rate. Anomaly detection is required to identify patterns that deviate from normal operational conditions which potentially indicate system disturbances. An unsupervised approach is chosen because operational data generally does not have anomaly labels.

This research uses deep learning methods with Transformer architecture to detect anomalies in multivariate time series data. Three models are compared: Transformer Autoencoder, TranAD, and Anomaly Transformer. The dataset used is oil and gas operational data from 2017-2021 with four main features: Pressure, Temperature, Volume Rate, and Energy Rate. The data is divided into 70% training, 15% validation, and 15% testing temporally.

Each model generates anomaly scores based on reconstruction error or discrepancy and is compared with the 90th percentile threshold. The research results show that Transformer Autoencoder detects the most anomalies but with the lowest score separation and stability. TranAD detects the fewest with the longest inference time. Anomaly Transformer provides optimal balance with the highest score separation, highest stability, and fastest inference time through the association discrepancy mechanism. Based on evaluation of sensitivity, stability, and computational efficiency, Anomaly Transformer proves to be the most suitable for oil and gas operational anomaly detection systems.

Keywords: *anomaly detection, Transformer, TranAD, Anomaly Transformer, autoencoder, multivariate time series.*

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas berkat dan penyertaan-Nya sehingga tugas akhir berjudul *“Deteksi Anomali Menggunakan Metode Transformer pada Data Operasional Migas”* dapat diselesaikan sebagai salah satu syarat kelulusan Program Sarjana S1 Sains Data.

Penelitian ini membahas pemanfaatan arsitektur Transformer, khususnya Transformer Autoencoder, TranAD, dan Anomaly Transformer, untuk mendeteksi pola penyimpangan pada data deret waktu multivariat dari sensor sistem perpipaan migas guna mendukung sistem pemantauan otomatis di lingkungan industri.

Ucapan terima kasih penulis sampaikan kepada dosen pembimbing, program studi, laboratorium, seluruh dosen dan staf Fakultas Informatika, serta keluarga dan teman-teman atas bimbingan, fasilitas, dan dukungan yang diberikan. Penulis menyadari adanya keterbatasan dalam laporan ini dan sangat mengharapkan kritik serta saran yang membangun agar karya ini dapat bermanfaat sebagai referensi ilmiah maupun pertimbangan praktis di masa mendatang.

UCAPAN TERIMA KASIH

Dalam proses penyusunan laporan ini, penulis mendapat banyak dukungan dari berbagai pihak. Oleh karena itu, dengan penuh rasa hormat penulis menyampaikan terima kasih kepada:

1. Tuhan Yang Maha Esa, atas kesehatan, kelancaran, dan kesempatan yang diberikan sehingga dapat menyelesaikan tugas akhir ini.
2. Bapak Dr. Aditya Firman Ihsan, S.Si., M.Si., selaku dosen pembimbing yang telah memberikan bimbingan, arahan, dan masukan yang sangat berarti selama proses penelitian.
3. Orang tua serta Keluarga, yang memberikan dukungan doa, moral, serta motivasi yang tidak pernah putus.
4. Bapak/Ibu Dosen dan staf Program Studi Sains Data, Fakultas Informatika Universitas Telkom, yang telah memberikan ilmu dan fasilitas selama masa studi.
5. Teman-teman seperjuangan, mahasiswa Sains Data Angkatan 2022, yang saling memberikan doa, dukungan, serta semangat.
6. Pihak lain yang penulis tidak dapat disebutkan satu per satu namun turut membantu dalam bentuk apa pun selama proses penelitian dan penulisan.

Semoga segala kebaikan dan bantuan yang telah diberikan mendapatkan balasan yang setimpal, dan semoga laporan ini dapat memberikan manfaat bagi perkembangan ilmu pengetahuan maupun praktik di bidang analitik data.

DAFTAR ISI

LEMBAR PENGESAHAN.....	ii
LEMBAR ORISINALITAS	iii
ABSTRAK	iv
<i>ABSTRACT</i>	v
KATA PENGANTAR	vi
UCAPAN TERIMA KASIH	vii
DAFTAR ISI.....	viii
DAFTAR GAMBAR	x
DAFTAR TABEL	xi
BAB 1 PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Tujuan	3
1.4. Batasan Masalah	4
1.5. Metode Penelitian	4
1.6. Jadwal Pelaksanaan	5
BAB 2 TINJAUAN PUSTAKA	6
2.1. Penelitian Terdahulu	6
2.2. Deteksi Anomali.....	7
2.3. Autoencoder untuk Deteksi Anomali.....	9
2.4. Arsitektur Transformer	10
2.5. Metode Deteksi Anomali Berbasis Transformer	11
2.5.1. Transformer Autoencoder (Baseline)	11
2.5.2. TranAD	13
2.5.3. Anomaly Transformer	16
BAB 3 PERANCANGAN SISTEM	19
3.1. Alur Penelitian	19
3.2. Dataset Penelitian	20
3.3. Pra-pemrosesan Data	21
3.3.1. Pembersihan Data	21
3.3.2. Agregasi Waktu	22
3.3.3. Normalisasi (<i>StandardScaler</i>).....	22

3.3.4.	Sliding Window	23
3.4.	Arsitektur Model Transformer	23
3.4.1.	Transformer Autoencoder	24
3.4.2.	TranAD	24
3.4.3.	Anomaly Transformer	25
3.4.4.	Implementasi Model	25
3.5.	Pelatihan Model	26
3.6.	Pengujian Model & Perhitungan Skor	27
3.7.	Penentuan Threshold	27
3.8.	Evaluasi Model dan Perbandingan Model	29
3.9.	Spesifikasi Perangkat Keras	30
BAB 4	HASIL PERCOBAAN DAN ANALISIS	31
4.1.	Hasil Pra-Pemrosesan Data	31
4.2.	Hasil <i>Tuning Hyperparameter</i>	32
4.3.	Hasil Deteksi Anomali pada Data Uji	33
4.4.	Evaluasi dan Hasil Perbandingan Model	35
BAB 5	KESIMPULAN DAN SARAN	37
5.1.	Kesimpulan	37
5.2.	Saran	38
DAFTAR PUSTAKA		39

DAFTAR GAMBAR

Gambar 2.1 Arsitektur Transformer Autoencoder	12
Gambar 2.2 Arsitektur TranAD	14
Gambar 2.3 Arsitektur Anomaly Transformer	16
Gambar 3.1 Flowchart Metodologi Penelitian	19
Gambar 3.2 Distribusi Skor Training dan <i>Threshold</i> P90 untuk Ketiga Model	28
Gambar 4.1 Visualisasi Pembagian Dataset <i>Train</i> , <i>Validation</i> dan <i>Test</i>	31
Gambar 4.2 Deteksi Anomali pada model Transformer Autoencoder pada data test.	33
Gambar 4.3 Deteksi Anomali pada model TranAD pada data test.	34
Gambar 4.4 Deteksi Anomali pada model Anomaly Transformer pada data test.	34

DAFTAR TABEL

Tabel 1.1 Pelaksanaan Tugas Akhir.....	5
Tabel 3.1 Konfigurasi <i>Sliding Window</i>	23
Tabel 4.1 Konfigurasi Hyperparameter Terbaik untuk setiap model.	32

BAB 1 PENDAHULUAN

1.1. Latar Belakang

Sistem perpipaan minyak dan gas (migas) merupakan salah satu infrastruktur yang memiliki peran penting dalam proses distribusi energi dari area produksi menuju fasilitas pemrosesan. Operasi perpipaan umumnya berlangsung secara kontinu dengan tekanan tinggi dan dipengaruhi oleh kondisi lingkungan yang dinamis, sehingga meningkatkan kompleksitas sistem.

Kerentanan terhadap gangguan operasi, termasuk kebocoran pipa, menjadi isu utama dalam upaya menjaga keamanan dan kontinuitas pasokan energi. Berdasarkan laporan *European Gas Pipeline Incident Data Group* (EGIG), tercatat lebih dari 1411 insiden kebocoran gas di kawasan Eropa pada periode 1970–2019 [1]. Insiden kebocoran yang tidak teridentifikasi secara cepat dapat menimbulkan risiko serius seperti kebakaran, ledakan, kerusakan lingkungan, dan gangguan ekonomi [2].

Selama proses operasi, sistem perpipaan menghasilkan data historis multivariat dari berbagai sensor, seperti tekanan, suhu, laju aliran, dan tingkat energi. Data ini bersifat deret waktu (*time series*) dan sangat besar volumenya. Kompleksitas hubungan antar variabel, ditambah ketergantungan temporal yang kuat, membuat deteksi anomali secara manual menjadi tidak efektif.

Ketika terjadi kerusakan sensor, lonjakan tekanan, gangguan aliran, atau tanda-tanda awal kebocoran, perilaku data sering menunjukkan pola fluktuatif, non-linear, dan sulit dikenali secara kasat mata. Oleh karena itu, diperlukan pendekatan otomatis yang mampu mengidentifikasi pola tidak normal secara adaptif dan presisi. Penelitian terdahulu menunjukkan bahwa metode *machine learning* dan *deep learning* telah berhasil mempelajari pola abnormal pada data operasional industri [3].

Model berbasis *Recurrent Neural Network* (RNN), seperti *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU), pernah menjadi metode populer dalam analisis *time series*. Namun, arsitektur ini memiliki keterbatasan dalam mempelajari ketergantungan jangka panjang serta kurang efisien pada data berskala besar. Arsitektur Transformer kemudian muncul sebagai solusi yang lebih unggul melalui pemanfaatan mekanisme *self-attention*, yang memungkinkan pemodelan hubungan temporal secara global [4].

Pengembangan lebih lanjut menghadirkan berbagai model Transformer untuk deteksi anomali, seperti TranAD dengan mekanisme *dual reconstruction* dan *adversarial learning* [5], serta Anomaly Transformer yang memanfaatkan *association discrepancy* untuk mengidentifikasi perbedaan pola normal dan abnormal [6]. Studi Oliveira et al. menunjukkan bahwa TranAD mampu mendeteksi penurunan produksi dan penutupan katup bawah tanah pada sistem sumur migas [7], sementara penelitian Aljameel et al. membuktikan bahwa model machine learning dapat mendeteksi kebocoran perpipaan secara efektif [8].

Selain itu, pendekatan autoencoder telah digunakan untuk pemeliharaan prediktif pada sistem perpipaan [9], sementara metode *generatif* seperti GAN-AD memberikan peningkatan performa deteksi pada data multivariat [10]. Model lain seperti Anomaly-PTG turut memperluas kemampuan Transformer dalam berbagai skenario [11]. Tren ini diperkuat oleh berbagai survei yang menegaskan bahwa penggunaan Transformer dan *deep learning* dalam analisis deret waktu terus meningkat pesat [12] [13] [14], serta menunjukkan hasil yang baik pada data operasional migas [15].

Meskipun demikian, sebagian besar penelitian sebelumnya hanya dilakukan pada dataset benchmark seperti *SwaT* (*Secure Water Treatment*), *WADI* (*Water Distribution*), *NAB* (*Numenta Anomaly Benchmark*), *SMD* (*Server Machine Dataset*), dan *MSL* (*Mars Science Laboratory*), sehingga belum banyak studi yang mengevaluasi performa model Transformer secara

langsung pada data operasional migas. Selain itu, belum ada studi yang membandingkan secara komprehensif Transformer Autoencoder, TranAD, dan Anomaly Transformer dalam satu kerangka evaluasi yang sama.

Berdasarkan kondisi tersebut, penelitian ini tidak berfokus pada pengembangan arsitektur Transformer baru, melainkan pada evaluasi dan analisis perilaku tiga model Transformer, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer, pada data operasional migas nyata yang bersifat multivariat dan tidak berlabel. Kontribusi utama penelitian ini terletak pada penyediaan masukan komparatif mengenai sensitivitas deteksi, stabilitas skor, serta efisiensi komputasi masing-masing model dalam satu kerangka evaluasi yang konsisten, yang masih jarang dibahas pada studi sebelumnya.

1.2. Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah yang diangkat dalam penelitian ini adalah sebagai berikut :

1. Bagaimana performa model Transformer Autoencoder sebagai model baseline dalam mendeteksi anomali?
2. Bagaimana karakteristik skor anomali yang dihasilkan oleh ketiga model Transformer, berdasarkan error rekonstruksi atau *discrepancy*?
3. Bagaimana perbandingan performa antara Transformer Autoencoder, TranAD dan Anomaly Transformer dalam mendeteksi anomali berdasarkan distribusi skor, jumlah anomali terdeteksi, dan kompleksitas model?

1.3. Tujuan

Tujuan yang ingin dicapai pada penelitian ini adalah sebagai berikut :

1. Mengevaluasi performa model Transformer Autoencoder sebagai model baseline dalam mendeteksi anomali pada data operasional migas.

2. Menganalisa karakteristik skor anomali yang dihasilkan dari model Transformer Autoencoder, TranAD dan Anomaly Transformer berdasarkan error rekonstruksi atau discrepancy.
3. Menilai dan membandingkan efektivitas model Transformer Autoencoder, TranAD dan Anomaly Transformer dalam mendeteksi anomali berdasarkan distribusi skor, jumlah anomali terdeteksi dan kompleksitas masing-masing model.

1.4. Batasan Masalah

Batasan Masalah yang ditetapkan dalam penelitian ini, sebagai berikut :

1. Ruang lingkup data dibatasi pada data operasional migas berbentuk deret waktu multivariat dan hanya menggunakan empat fitur utama yaitu *Temperature, Pressure, Volume Rate, dan Energy Rate*.
2. Model yang digunakan dibatasi pada tiga arsitektur berbasis Transformer, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer. Model lain yang berpotensi relevan tidak dibahas karena keterbatasan waktu implementasi dan kompleksitas algoritma.
3. Evaluasi performa difokuskan pada metrik deteksi anomali seperti distribusi skor anomali, jumlah anomali terdeteksi, waktu inferensi, dan kompleksitas model. Aspek seperti *robustness* terhadap *noise*, serangan *adversarial*, atau stabilitas jangka panjang tidak dievaluasi.
4. Cakupan penelitian tidak mencakup implementasi sistem deteksi anomali secara real-time maupun integrasi dengan sistem kontrol industri, karena hal tersebut membutuhkan perangkat lunak tambahan, infrastruktur industri, dan pengujian lapangan di luar ruang lingkup penelitian ini.

1.5. Metode Penelitian

Pekerjaan penelitian ini dilakukan melalui pendekatan kuantitatif dengan menggunakan teknik *deep learning* berbasis arsitektur Transformer untuk mengidentifikasi anomali pada data operasional migas. Metode yang digunakan meliputi studi teoritis/literatur untuk memahami konsep dan

arsitektur Transformer, pra-pemrosesan data deret waktu multivariat, perancangan serta penerapan tiga model (Transformer Autoencoder, TranAD, dan Anomaly Transformer), pelatihan model menggunakan data pelatihan, serta evaluasi performa dari tiap model. Seluruh tahapan penelitian dilakukan secara eksperimental dengan menggunakan dataset operasional migas periode 2017 sampai 2021.

1.6. Jadwal Pelaksanaan

Tabel 1.1 menunjukkan jadwal pelaksanaan tugas akhir.

Tabel 1.1 Pelaksanaan Tugas Akhir.

No.	Deskripsi Tahapan	Bulan 1	Bulan 2	Bulan 3	Bulan 4	Bulan 5	Bulan 6
1	Studi Literatur						
2	Pengumpulan Data & Pemahaman Data						
3	Pra-pemrosesan Data						
4	Implementasi Model Transformer Autoencoder, TranAD, dan Anomaly Transformer						
5	Evaluasi & Analisis Hasil						
6	Penyusunan Laporan/Buku TA						

BAB 2 TINJAUAN PUSTAKA

2.1. Penelitian Terdahulu

Penelitian mengenai deteksi anomali pada data deret waktu multivariat telah banyak dilakukan, termasuk pada sektor minyak dan gas yang memiliki karakter data kompleks dan sangat bergantung pada sistem pemantauan berbasis sensor. Sejumlah studi awal memanfaatkan pendekatan *machine learning* tradisional, seperti yang dilakukan oleh Aljameel et al., yang menunjukkan bahwa model seperti Random Forest dan XGBoost mampu mendeteksi anomali terkait kebocoran pipa dengan akurasi tinggi menggunakan kombinasi data sensor dan aliran fluida [8]. Di sisi lain, penelitian oleh Audibert et al. menunjukkan bahwa pendekatan berbasis autoencoder efektif untuk deteksi anomali secara tidak terawasi pada data deret waktu multivariat, dengan memanfaatkan kesalahan rekonstruksi untuk mengidentifikasi pola perilaku yang menyimpang [9].

Seiring berkembangnya arsitektur *deep learning*, Transformer mulai banyak diterapkan dalam tugas deteksi anomali karena kemampuannya menangkap hubungan temporal secara lebih menyeluruh dibandingkan model berbasis RNN. Tuli et al. memperkenalkan TranAD, sebuah model Transformer yang menggabungkan mekanisme *dual reconstruction* dan *adversarial learning*. Model ini menunjukkan performa unggul pada dataset *NAB*, *SWaT*, dan *WADI*, dengan F1-score mencapai 0,94 pada *SWaT* [5]. Penggunaannya pada sistem produksi migas oleh Oliveira et al. memberikan hasil positif, khususnya dalam mendeteksi penurunan produksi mendadak dan perilaku katup yang tidak biasa [7]. Selain itu, Xu et al. mengembangkan Anomaly Transformer, yang mengandalkan mekanisme *association discrepancy* untuk menilai perubahan hubungan temporal pada data multivariat. Model ini memperoleh rata-rata F1-score 0,86 pada berbagai benchmark publik seperti *SMD* dan *MSL* [6].

Beberapa penelitian lain turut menunjukkan potensi besar Transformer dalam mendeteksi anomali multivariat. Zhang et al. mengusulkan metode berbasis *Time Difference of Arrival* (TDOA) dan uji *Kolmogorov–Smirnov* untuk mendeteksi kebocoran pipa gas dengan tingkat deteksi hingga 95% pada simulasi realistis [2]. Xu et al. memperluas pendekatan ini melalui TGAN-AD, sebuah model hybrid berbasis Transformer dan GAN yang mempelajari distribusi data normal dengan lebih kompleks [10]. Sementara itu, Shimillas et al. mengembangkan dua metrik baru yaitu *Space-Time Anomaly Score* (STAS) dan *Statistical Feature Anomaly Score* (SFAS), untuk meningkatkan kemampuan lokalisasi anomali pada data multivariat menggunakan arsitektur Transformer .

Secara umum, studi-studi tersebut menunjukkan bahwa Transformer dan turunannya memiliki kemampuan yang kuat dalam mempelajari pola temporal dan mengidentifikasi penyimpangan pada data industri. Namun, sebagian besar penelitian masih berfokus pada dataset benchmark seperti SWaT, WADI, NAB, SMD, atau MSL. Evaluasi langsung pada data operasional migas nyata masih terbatas, dan belum banyak studi yang membandingkan Transformer Autoencoder, TranAD, dan Anomaly Transformer secara setara dalam kondisi data yang sama. Oleh karena itu, penelitian ini mencoba mengisi kekosongan tersebut dengan mengevaluasi ketiga model tersebut pada data operasional migas tahun 2017–2021 menggunakan prosedur pra-pemrosesan dan metrik evaluasi yang seragam.

2.2. Deteksi Anomali

Deteksi anomali merupakan proses untuk menemukan pola atau perilaku data yang tidak sesuai dengan kondisi normal. Dalam banyak sistem industri, termasuk sistem perpipaan migas, anomali dapat menunjukkan adanya tanda-tanda gangguan seperti kerusakan sensor, lonjakan tekanan, perubahan suhu yang tidak wajar, atau potensi kebocoran. Kondisi seperti ini perlu dideteksi lebih awal agar tidak berkembang menjadi kerusakan yang lebih besar dan membahayakan operasi industri [12].

Secara umum, anomali dapat dibagi menjadi beberapa jenis. *Point anomaly* terjadi ketika satu titik data berbeda jauh dari nilai biasanya. *Contextual anomaly* muncul ketika data dianggap tidak normal hanya pada kondisi tertentu, misalnya pada waktu tertentu. Sementara itu, *collective anomaly* terjadi ketika sekelompok data bersama-sama menunjukkan pola yang tidak biasa meskipun nilai individualnya tampak normal [12]. Pembagian ini membantu dalam memahami karakter gangguan yang mungkin muncul pada data operasional.

Berbagai metode telah dikembangkan untuk mendeteksi anomali. Metode statistik dapat digunakan untuk data sederhana, namun sering tidak cukup untuk data yang memiliki pola kompleks. Pendekatan lain seperti *machine learning* tradisional juga dapat dipakai, tetapi tetap memiliki keterbatasan dalam menangani data multivariat dan hubungan temporal yang panjang. Karena itu, metode berbasis *deep learning* semakin banyak digunakan karena mampu mempelajari pola data yang lebih rumit dan non-linear [15].

Dalam penelitian sebelumnya, *deep learning* dinilai efektif dalam mendeteksi anomali pada berbagai jenis data industri. Salah satu keunggulannya adalah kemampuannya untuk belajar langsung dari data tanpa perlu banyak aturan manual, sehingga lebih adaptif terhadap pola nyata pada data operasional [12]. Hal ini sangat relevan untuk data migas yang memiliki karakteristik deret waktu multivariat dengan banyak variasi dan perubahan kondisi selama operasi.

Pada penelitian ini, deteksi anomali dilakukan dengan cara menghitung seberapa jauh suatu segmen data menyimpang dari pola normal. Ketiga model yang digunakan, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer, menghasilkan skor anomali berdasarkan rekonstruksi atau perbedaan hubungan temporal. Skor tersebut kemudian dibandingkan dengan ambang batas (*threshold*) tertentu untuk menentukan apakah suatu data dapat dikategorikan sebagai anomali. Pendekatan ini dipilih karena mampu menangani data sensor migas yang bersifat kompleks dan berubah-

ubah, sehingga cocok untuk mendukung sistem pemantauan otomatis di lingkungan industri.

2.3. Autoencoder untuk Deteksi Anomali

Autoencoder adalah model *deep learning* yang digunakan untuk mempelajari pola sebuah data dengan cara merangkum informasi penting lalu mencoba membentuk kembali data tersebut. Pada *autoencoder* terdapat dua bagian utama. Bagian pertama, yaitu *encoder*, bertugas mengubah data awal menjadi representasi yang lebih ringkas. Setelah itu, *decoder* mengambil representasi tersebut dan mencoba merekonstruksi data seperti semula. Apabila pola data sudah dipelajari dengan baik, hasil rekonstruksi yang dihasilkan akan sangat mirip dengan data aslinya.

Pada kasus deteksi anomali, prinsip *autoencoder* dimanfaatkan dengan melihat besar kesalahan rekonstruksi. Data yang mengikuti pola normal umumnya lebih mudah direkonstruksi karena karakteristiknya telah dipelajari selama proses pelatihan. Sebaliknya, data yang tidak umum atau menyimpang akan menghasilkan selisih lebih besar antara input dan output. Oleh sebab itu, rekonstruksi dapat dijadikan dasar untuk menilai apakah suatu data berada pada kondisi wajar atau tidak [9].

Model *autoencoder* cukup fleksibel dan dapat digunakan pada berbagai jenis data, termasuk deret waktu. Untuk data sensor industri, model ini membantu memahami hubungan antar fitur dan pola perubahan yang muncul dari waktu ke waktu. Namun, beberapa penelitian mencatat bahwa autoencoder standar memiliki keterbatasan dalam mengatasi pola temporal yang panjang atau sangat kompleks, sehingga performanya bisa menurun pada data multivariat tertentu [12]. Meskipun begitu, pendekatan ini tetap dianggap efektif sebagai model dasar sebelum menggunakan arsitektur yang lebih khusus.

Dalam penelitian ini, *autoencoder* berbasis Transformer digunakan sebagai model *baseline*. Pendekatan ini dipilih agar proses rekonstruksi tidak hanya melihat hubungan antar fitur, tetapi juga dapat memanfaatkan mekanisme

perhatian (*attention*) untuk memahami ketergantungan waktu. Hasil rekonstruksi dari model baseline ini nantinya digunakan sebagai pembanding terhadap dua model lainnya, yaitu TranAD dan Anomaly Transformer. Dengan cara ini, penelitian dapat melihat sejauh mana peningkatan performa yang diberikan oleh model-model yang lebih kompleks.

2.4. Arsitektur Transformer

Transformer merupakan model yang cukup berpengaruh dalam perkembangan *deep learning* modern. Model ini diperkenalkan pada tahun 2017 oleh Vaswani dan rekan-rekannya [4] dan langsung menjadi dasar bagi berbagai metode pemrosesan data berurutan. Berbeda dengan pendekatan lama seperti RNN dan variannya, Transformer tidak membaca data satu per satu, tetapi melihat keseluruhan urutan secara bersamaan. Cara kerja seperti ini membuat proses komputasi menjadi lebih cepat dan memungkinkan model menangkap pola yang jaraknya saling berjauhan.

Salah satu gagasan utama yang membuat Transformer efektif adalah kemampuannya memilih bagian data mana yang paling relevan ketika sedang memproses sebuah urutan. Mekanisme ini lebih dikenal sebagai *attention*. Dalam praktiknya, setiap elemen di dalam sebuah urutan dapat menilai seberapa kuat hubungannya dengan elemen-elemen lain. Dengan begitu, model dapat memfokuskan pemrosesan pada bagian yang dianggap penting. Pada data sensor industri, kondisi seperti ini sering terjadi karena satu perubahan bisa saja dipengaruhi oleh beberapa kondisi lain dalam waktu yang berdekatan.

Untuk mendapatkan pemahaman yang lebih kaya, proses perhatian tersebut biasanya dijalankan dalam beberapa jalur secara paralel. Setiap jalur mencoba melihat pola dari sudut yang berbeda, sehingga hasil akhirnya memberikan gambaran yang lebih lengkap. Pendekatan seperti ini banyak membantu ketika data memiliki hubungan antar fitur yang rumit atau tidak selalu mengikuti pola yang sama.

Berbeda dari metode berurutan seperti RNN, Transformer tidak secara otomatis mengetahui posisi sebuah data dalam rangkaian waktu. Agar model tetap memahami urutan kejadian, diberikan tambahan informasi khusus yang menandai posisi relatif setiap titik data. Informasi ini dapat dianggap sebagai “tanda waktu” yang memungkinkan model mengenali mana data yang muncul lebih awal, mana yang muncul setelahnya, dan bagaimana hubungan keduanya. Dengan cara ini, proses paralel yang dilakukan Transformer tetap mempertahankan konteks temporal yang penting dalam analisis deret waktu.

Kombinasi dari mekanisme perhatian, pemrosesan paralel, dan penanda posisi tersebut membuat Transformer cukup kuat saat digunakan pada data yang memiliki banyak variabel dan pola temporal yang kompleks. Oleh sebab itu, pada penelitian ini, arsitektur Transformer digunakan sebagai dasar dari ketiga model yang dibandingkan, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer. Seluruh model memanfaatkan kemampuan Transformer untuk mempelajari pola sensor migas dan mendeteksi perubahan yang dapat mengindikasikan anomali.


2.5. Metode Deteksi Anomali Berbasis Transformer

Dalam penelitian ini digunakan tiga model utama yang seluruhnya berlandaskan arsitektur Transformer. Setiap model memiliki mekanisme perhitungan skor anomali yang berbeda, sehingga karakteristik dari hasil deteksi tiap model berbeda.

2.5.1. Transformer Autoencoder (Baseline)

Transformer Autoencoder digunakan sebagai model dasar dalam penelitian ini untuk mengenali pola normal dari data sensor. Pendekatan ini tidak langsung menilai apakah suatu pengamatan termasuk anomali, tetapi terlebih dahulu mempelajari kebiasaan atau karakter umum dari data historis. Setelah menerima banyak contoh data tanpa label, model diminta untuk menghasilkan kembali sinyal yang mirip dengan masukan pertama. Biasanya, ketika data mengikuti pola umum yang muncul selama proses pelatihan,

model dapat menyusun kembali sinyal dengan cukup baik. Namun rekonstruksinya menjadi kurang akurat ketika suatu bagian data berbeda jauh dari pola awal. Perbedaan ini kemudian digunakan sebagai dasar indikasi adanya anomali. Gambaran alur kerjanya diperlihatkan pada Gambar 2.1.



Gambar 2.1 Arsitektur Transformer Autoencoder

Berdasarkan Gambar 2.1, data masukan tidak diproses secara langsung, melainkan melalui tahapan peringkasan dan rekonstruksi. Data input berupa matriks jendela waktu yang memuat nilai beberapa fitur sensor pada sejumlah langkah waktu. Matriks ini terlebih dahulu diproyeksikan dan diperkaya dengan informasi posisi waktu, kemudian diproses oleh Transformer Encoder untuk menghasilkan representasi laten dalam bentuk matriks fitur terencode. Tahap peringkasan ini memungkinkan model menangkap pola temporal serta hubungan antar fitur yang dominan pada data operasional normal.

Representasi laten tersebut selanjutnya diteruskan ke Transformer Decoder untuk direkonstruksi kembali menjadi matriks keluaran dengan ukuran yang sama seperti input awal. Pada kondisi normal, hasil rekonstruksi mendekati data asli, sedangkan pada kondisi tidak normal model cenderung gagal merekonstruksi sinyal dengan baik. Perbedaan antara matriks input dan matriks hasil rekonstruksi dihitung sebagai nilai galat rekonstruksi dalam bentuk bilangan tunggal menggunakan Mean Squared Error (MSE). Nilai galat ini digunakan sebagai skor anomali, di mana nilai yang lebih besar mengindikasikan tingkat penyimpangan yang semakin tinggi.

Untuk menghitung selisih antara sinyal asli dan hasil rekonstruksi, penelitian ini menggunakan Mean Squared Error (MSE). Rumusnya adalah:

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad (2.1)$$

dengan :

x_i adalah nilai data asli pada indeks ke- i ,

$\hat{x}_i$ adalah nilai hasil rekonstruksi pada indeks ke- i ,


n adalah jumlah titik data dalam satu window perhitungan.

Titik data dengan nilai *error* yang jauh lebih besar dibandingkan pola normal umumnya dianggap sebagai kandidat anomali.

Transformer Autoencoder dipilih sebagai baseline karena arsitekturnya relatif sederhana namun cukup efektif dalam mempelajari pola temporal pada data multivariat. Penggunaan model ini juga mempermudah analisis awal sebelum dilakukan perbandingan dengan dua model Transformer lainnya.

2.5.2. TranAD

TranAD merupakan salah satu model deteksi anomali berbasis Transformer yang dirancang khusus untuk mempelajari perubahan pola pada data deret waktu multivariat. TranAD menggunakan dua tahap rekonstruksi yang berjalan secara berurutan, berbeda dengan autoencoder konvensional yang hanya melakukan satu rekonstruksi. Tujuan dari mekanisme dua tahap ini adalah untuk membuat model lebih peka terhadap kesalahan kecil yang tidak terlihat selama proses rekonstruksi awal. Model belajar membedakan pola perubahan yang wajar dari pola yang menunjukkan gangguan selama proses pelatihan. Ini memungkinkan hasil rekonstruksi digunakan sebagai penanda potensi anomali. Metode ini membuat TranAD ideal untuk digunakan dalam lingkungan operasional yang selalu berubah, seperti sistem pipa migas di mana perubahan tekanan, suhu, atau laju aliran dapat terjadi secara tiba-tiba dan berdampak satu sama lain [5].



Gambar 2.2 Arsitektur TranAD

Berdasarkan Gambar 2.2, model TranAD menerima dua jenis masukan. Masukan pertama adalah jendela data (W) berupa matriks window yang berisi nilai terbaru dari beberapa fitur sensor pada sejumlah langkah waktu dan menjadi target utama untuk direkonstruksi. Masukan kedua adalah data konteks (C) berupa rangkaian data sebelumnya yang merepresentasikan kondisi historis sistem. Kedua masukan ini terlebih dahulu diproyeksikan dan diperkaya dengan informasi posisi waktu, kemudian diproses secara bersama melalui window encoder dan encoder utama menggunakan mekanisme multi-head attention. Pada tahap ini, model mempelajari hubungan antar waktu dan antar fitur untuk membentuk representasi laten yang merangkum pola temporal dari data normal.

Setelah proses encoding selesai, representasi laten tersebut diteruskan ke dua tahap decoding. Decoder pertama menghasilkan rekonstruksi awal dari jendela data masukan, sedangkan decoder kedua memanfaatkan hasil rekonstruksi pertama beserta informasi konteks untuk menghasilkan rekonstruksi lanjutan. Kedua hasil rekonstruksi ini kemudian dibandingkan dengan data asli untuk menghasilkan nilai galat rekonstruksi dalam bentuk bilangan tunggal. Perbedaan karakteristik galat dari kedua tahap rekonstruksi tersebut digunakan sebagai skor anomali, yang mencerminkan sejauh mana

suatu sampel menyimpang dari pola perilaku normal yang telah dipelajari oleh model.

Untuk menghitung nilai error dapat digunakan **Mean Squared Error** (MSE) antara data asli dan hasil rekonstruksi :

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2 \quad (2.2)$$

Secara matematis, rumus ini digunakan dua kali untuk dua output rekonstruksi :

$$Error_1 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_{1,i})^2 \quad (2.3)$$

$$Error_2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_{2,i})^2 \quad (2.4)$$

Dimana :

x_i = nilai data asli pada indeks ke-i,

$\hat{x}_{1,i}$ = nilai hasil rekonstruksi tahap pertama,

$\hat{x}_{2,i}$ = nilai hasil rekonstruksi tahap kedua,

n = jumlah titik data dalam satu window perhitungan.

Untuk menentukan skor anomali, digunakan selisih absolut antara kedua error :

$$Score = |Error_1 - Error_2| \quad (2.5)$$


Semakin besar nilainya, maka semakin besar juga kemungkinan titik data tersebut merupakan anomali.

TranAD dipilih dalam penelitian ini karena mekanisme dua langkah rekonstruksinya membuat model lebih peka terhadap perubahan kecil pada data operasional migas. Karena sifat data yang berubah-ubah, misalnya akibat fluktuasi tekanan, suhu, atau laju aliran, menuntut model yang mampu

membaca pola tidak wajar meskipun penyimpangannya halus. Dengan dua tahap rekonstruksi yang digunakan sebagai dasar perhitungan skor anomali, TranAD dapat memberikan informasi yang lebih, terutama mengenai kemungkinan **terjadinya** gangguan pada sistem perpipaan migas.

2.5.3. Anomaly Transformer

Anomaly Transformer merupakan salah satu pendekatan deteksi anomali yang dibangun di atas arsitektur Transformer, namun cara kerjanya tidak sama dengan model yang mengandalkan rekonstruksi. Alih-alih mencoba meniru kembali sinyal masukan seperti autoencoder atau TranAD, model ini justru menilai hubungan antar titik waktu pada data sensor. Dalam keadaan normal, hubungan tersebut biasanya membentuk pola tertentu yang relatif stabil. Ketika muncul gangguan, pola keterkaitan ini ikut berubah, dan dari perubahan inilah model mencoba mengenali apakah suatu segmen data mengarah pada perilaku yang tidak biasa pada deret waktu multivariat [6].



Gambar 2.3 Arsitektur Anomaly Transformer

Berdasarkan Gambar 2.3, proses pada Anomaly Transformer diawali dengan pengolahan data masukan berupa *value* matriks jendela waktu yang kemudian diproyeksikan menjadi representasi *query*, *key*, dan sebagaimana pada Transformer standar. Berbeda dari mekanisme perhatian konvensional, model ini menghitung dua jenis hubungan temporal. *Series-association* diperoleh melalui mekanisme *self-attention* dan merepresentasikan keterkaitan antar titik waktu yang dipelajari langsung dari data. Sementara itu, *prior-association* dibentuk berdasarkan distribusi *Gaussian* sebagai *prior*,

yang merepresentasikan pola hubungan temporal yang diharapkan terjadi pada kondisi normal.

Kedua hubungan tersebut kemudian dibandingkan untuk menghasilkan *association discrepancy*, yang mencerminkan tingkat ketidaksesuaian antara pola aktual data dan pola normal yang diasumsikan oleh *prior*. Pada kondisi normal, *series-association* dan *prior-association* cenderung selaras, sedangkan pada kondisi anomali keduanya menunjukkan perbedaan yang signifikan. Nilai perbedaan inilah yang digunakan sebagai dasar pembentukan skor anomali. Meskipun arsitektur ini juga mencakup blok rekonstruksi, proses rekonstruksi tidak ditujukan untuk mengembalikan sinyal ke bentuk semula, melainkan berfungsi sebagai mekanisme pendukung untuk menstabilkan pembelajaran hubungan temporal agar model mampu mempelajari pola normal secara konsisten.

Pada Anomaly Transformer, nilai anomali dihitung berdasarkan perbedaan antara hubungan *prior* dan hubungan aktual yang dipelajari model. Rumus dasar discrepancy adalah:

$$D_t = \sum_{i=1}^n |A_{t,i}^{(series)} - A_{t,i}^{(prior)}| \quad (2.6)$$

Dengan :

$A_{t,i}^{(series)}$ = attention aktual,

$A_{t,i}^{(prior)}$ = perhatian prior,

D_t = discrepancy pada waktu ke-t

Skor anomali ditentukan dengan menggunakan discrepancy tersebut :


$$Score_t = D_t \quad (2.7)$$

Semakin besar nilainya, semakin besar kemungkinan titik waktu tersebut merupakan anomali.

Penggunaan model ini dalam penelitian didasari kemampuannya menangkap dinamika hubungan waktu secara lebih detail. Dengan memanfaatkan perbedaan antara hubungan yang diharapkan (*prior*) dan hubungan yang muncul dari data (*series*), model dapat melihat penyimpangan yang tidak selalu terlihat melalui pendekatan rekonstruksi. Hal tersebut membuat Anomaly Transformer cukup sesuai untuk data sensor migas yang sifatnya saling bergantung dan sering mengalami variasi. Melalui pengukuran *discrepancy* tersebut, model memberikan indikasi anomali yang lebih kaya sehingga dapat melengkapi hasil dari pendekatan deteksi berbasis rekonstruksi.

BAB 3 PERANCANGAN SISTEM

3.1. Alur Penelitian



Gambar 3.1 Flowchart Metodologi Penelitian

Gambar 3.1 memperlihatkan langkah-langkah yang dilakukan dalam mendeteksi anomali pada data operasional migas. Dalam penelitian ini digunakan tiga model berbasis Transformer, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer. Ketiganya bekerja pada data sensor yang tersimpan sebagai deret waktu, misalnya data tekanan, suhu, laju energi, dan laju volume yang dikumpulkan dari sistem pipa.

Proses dimulai ketika data sensor dimasukkan ke dalam sistem. Setelah itu dilakukan tahap pra-pemrosesan, di mana data diperiksa dan dibersihkan dari

nilai yang keliru atau tidak lengkap. Fitur-fitur kemudian disesuaikan skalanya dan data disusun ulang ke dalam bentuk jendela waktu. Bentuk data seperti ini diperlukan agar bisa diproses oleh ketiga model yang digunakan.

Pada tahap selanjutnya, data yang sudah dipersiapkan diproses oleh masing-masing model sesuai mekanismenya. Transformer Autoencoder berusaha merekonstruksi kembali data input dan menghitung selisihnya sebagai error. TranAD melakukan dua proses rekonstruksi dan membandingkan kedua error tersebut untuk mendapatkan skor anomali. Sementara itu, Anomaly Transformer menghasilkan skor berdasarkan perbedaan pola hubungan antar titik waktu dalam sekuens data.

Nilai error atau skor yang dihasilkan setiap model kemudian dikumpulkan pada tahap perhitungan skor anomali. Di sini skor yang diperoleh dibandingkan dengan nilai ambang yang sudah ditentukan sebelumnya. Bila skor melewati ambang tersebut, data dianggap mengandung anomali. Jika tidak, data dikategorikan sebagai kondisi normal.

Tahap terakhir adalah penentuan hasil akhir. Sistem menandai setiap bagian data sebagai normal atau anomali sesuai hasil perbandingan dengan threshold. Hasil ini nantinya dapat digunakan untuk memantau kondisi operasional pipa migas dan membantu proses pengambilan keputusan terkait keamanan dan performa sistem secara keseluruhan.

3.2. Dataset Penelitian

Data yang digunakan dalam penelitian ini berasal dari data operasional perpipaan gas alam yang dicatat secara berkala oleh sensor. Data ini disusun dalam deret waktu multivariat dengan interval pencatatan satu jam. Meskipun data tersedia dari tahun 2013 hingga 2021, penelitian ini hanya menggunakan data tahun 2017 hingga 2021 saja.

Secara keseluruhan, dataset memiliki 21 atribut dengan total 309.964 baris. Dataset termasuk penanda waktu (*DATE STAMP*), tekanan, suhu, laju energi, laju volume, serta berbagai komponen gas. Namun, penelitian ini hanya

menggunakan sebagian fitur yang dianggap paling relevan, yaitu “*PRESSURE*”, “*TEMPERATURE*”, “*ENERGY RATE*”, dan “*VOLUME RATE*”. Ke-empat fitur tersebut dipilih berdasarkan penelitian-penelitian sebelumnya yang menunjukkan bahwa “*PRESSURE*” dan “*TEMPERATURE*” merupakan indikator utama deteksi anomali, sedangkan “*ENERGY RATE*” dan “*VOLUME RATE*” merepresentasikan laju aliran dan efisiensi energi sistem operasional.

Karena data tidak memiliki label anomali, pendekatan yang digunakan bersifat tidak terawasi (*unsupervised*). Sebelum diproses lebih lanjut, dilakukan pembersihan dataset, lalu dataset dibagi menjadi tiga bagian yaitu pelatihan, validasi dan pengujian berdasarkan urutan waktu.

3.3. Pra-pemrosesan Data

Sebelum data digunakan untuk pelatihan dan evaluasi model, tahap pra-pemrosesan sangat penting. Sensor tidak selalu mengumpulkan data operasional migas dalam kondisi siap pakai. Mungkin ada nilai kosong, pencatatan yang tidak konsisten, atau perbedaan skala antar fitur. Model berisiko mengidentifikasi anomali yang tidak stabil jika kondisi tersebut dibiarkan.

Oleh karena itu, seluruh dataset harus melalui proses pra-pemrosesan. Proses utama yang dilakukan termasuk pembersihan data, pemilihan fitur, agregasi waktu, normalisasi, dan pembentukan jendela waktu yang bergerak untuk menyesuaikan bentuk data dengan persyaratan model Transformer. Setiap langkah direncanakan untuk memastikan bahwa representasi data yang masuk ke dalam model konsisten dan dapat menggambarkan pola operasional yang sebenarnya.

3.3.1. Pembersihan Data

Tahap pembersihan data dilakukan untuk memastikan bahwa hanya data yang valid yang digunakan dalam pemodelan. Dataset operasional migas periode 2017–2021 awalnya memiliki 304.964 baris dan 21 kolom, kemudian diperiksa untuk mendeteksi baris dengan nilai tidak sesuai pada fitur utama,

seperti nilai 0 pada keempat fitur “PRESSURE”, “TEMPERATURE”, “ENERGY_RATE”, dan “VOLUME_RATE” secara bersamaan.

Pemeriksaan awal menunjukkan adanya 1.004 baris dengan nilai 0 pada seluruh fitur utama tersebut, sehingga baris-baris ini dihapus dan menyisakan 303.960 baris data valid sebelum proses agregasi dilakukan. Selain itu, hanya empat fitur utama yang dipertahankan, sedangkan fitur lain yang tidak digunakan dihilangkan untuk menyederhanakan pemodelan dan menyesuaikan ruang fitur dengan fokus penelitian.

3.3.2. Agregasi Waktu

Data sensor pada sistem perpipaan migas dicatat pada interval yang relatif rapat sehingga menghasilkan rangkaian nilai yang sangat detail. Kondisi ini sering menimbulkan fluktuasi kecil yang tidak selalu menggambarkan perubahan operasional yang penting. Jika digunakan secara langsung, variasi semacam ini dapat mengganggu proses pembelajaran model dan membuat deteksi anomali menjadi kurang stabil.

Penelitian ini menggunakan metode agregasi waktu untuk mengurangi efek tersebut. Diringkas menjadi satu nilai representatif untuk setiap kelompok data dalam rentang waktu tertentu. Data yang semula berjumlah 303.960 baris direduksi menjadi 43.601 baris. Penggunaan median membantu mempertahankan pola umum sensor sambil mengurangi pengaruh lonjakan sesaat yang dapat berasal dari noise atau gangguan pencatatan.

3.3.3. Normalisasi (*StandardScaler*)

Setelah agregasi, keempat fitur utama masih memiliki satuan dan rentang nilai yang berbeda sehingga berpotensi menyebabkan model lebih memprioritaskan fitur dengan skala lebih besar. Untuk menghindari ketidakseimbangan ini, seluruh fitur dinormalisasi menggunakan *StandardScaler* sehingga masing-masing memiliki rata-rata nol dan deviasi standar satu.

Normalisasi ini membantu mempercepat stabilitas proses pelatihan dan memastikan bahwa mekanisme *self-attention* pada Transformer tidak bias terhadap fitur tertentu hanya karena perbedaan skala nilai. Hasil normalisasi inilah yang kemudian digunakan sebagai dasar untuk membentuk jendela waktu dan menjadi input bagi ketiga model Transformer pada tahap pelatihan dan pengujian.

3.3.4. Sliding Window

Setelah proses normalisasi, deret waktu diubah menjadi bentuk yang sesuai dengan kebutuhan model Transformer. Model berbasis Transformer memerlukan input berupa urutan data dengan panjang tertentu agar pola hubungan antar waktu dapat dipelajari dengan baik. Untuk itu digunakan teknik sliding window.

Dalam penelitian ini digunakan *window size* 128 dan *step size* 1, sehingga setiap jendela berisi 128 titik waktu berturut-turut. Penerapan *sliding window* pada data hasil agregasi dan normalisasi dapat dilihat pada Tabel 3.1, dengan masing-masing window direpresentasikan dalam bentuk *tensor* berukuran (128, 4). Struktur ini memungkinkan ketiga model Transformer mempelajari ketergantungan temporal dan keterkaitan antar fitur secara efektif.

Tabel 3.1 Konfigurasi *Sliding Window*

Sliding Window	input_size, window size, feature
Train Windows	30393, 128, 4
Validation Windows	6413, 128, 4
Test Windows	6414, 128, 4

3.4. Arsitektur Model Transformer

Penelitian ini menggunakan tiga model berbasis arsitektur Transformer, yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer. Ketiga model ini dipilih karena mampu menangani data deret waktu multivariat dan mempelajari pola temporal secara lebih efektif dibandingkan metode

tradisional. Meskipun memiliki tujuan yang sama, masing-masing model memiliki mekanisme pemrosesan dan perhitungan skor anomali yang berbeda.

Seluruh model menerima input dalam bentuk jendela waktu berukuran (batch_size, 128, 4) yang telah dibentuk pada tahap pra-pemrosesan, di mana 128 adalah panjang sequence dan 4 adalah jumlah fitur (*PRESSURE*, *TEMPERATURE*, *VOLUME_RATE*, *ENERGY_RATE*). Arsitektur Transformer digunakan sebagai dasar untuk menangkap hubungan antar waktu dan antar fitur dalam setiap window melalui mekanisme *self-attention*. Setiap model kemudian menghasilkan skor anomali berdasarkan pendekatan yang digunakan, baik melalui rekonstruksi sinyal maupun perhitungan *association discrepancy*.

3.4.1. Transformer Autoencoder

Model dasar untuk mempelajari pola normal data melalui proses rekonstruksi adalah Transformer autoencoder, yang terdiri dari encoder yang mengubah input ke representasi laten dan decoder yang mencoba mengembalikan bentuk aslinya. Tingkat kesalahan rekonstruksi digunakan untuk menunjukkan betapa dekatnya data dengan pola normal. Jika nilai error jendela data tinggi, itu dianggap menyimpang dari struktur umum yang berhasil dipelajari model. Struktur transformer autoencoder memungkinkan menangani ketergantungan temporal dalam jendela data, sehingga lebih efisien untuk data operasional migas multivariat.

3.4.2. TranAD

TranAD menggunakan mekanisme rekonstruksi dua tahap untuk mendeteksi anomali. Rekonstruksi dasar dibuat pada tahap pertama, dan hasil diperbaiki pada tahap kedua dengan mempertimbangkan kesalahan dari tahap sebelumnya. Perbedaan antara kedua tahap ini membuat model lebih sensitif terhadap perubahan data yang halus. Komponen pembelajaran adversarial yang digunakan TranAD juga membantu model membedakan antara pola

normal dan pola yang dianggap tidak wajar. Pendekatan dua tahap ini membuat TranAD lebih responsif terhadap perubahan data operasional yang kecil atau besar.

3.4.3. Anomaly Transformer

Anomaly Transformer model ketiga yang digunakan untuk mengidentifikasi anomali berdasarkan pola hubungan antar waktu dalam jendela data. Model ini menerima input berupa window yang telah melalui tahap agregasi, normalisasi, dan pembentukan deret waktu. Berbeda dengan model rekonstruksi, Anomaly Transformer tidak menghasilkan sinyal prediksi ulang; sebaliknya, dia menghitung skor anomali berdasarkan perbedaan pola ketergantungan temporal yang terjadi di setiap jendela.

Selama pelatihan, model mempelajari hubungan temporal yang dianggap normal dari data historis. Pada tahap pengujian, skor anomali dihitung dengan membandingkan pola hubungan tersebut dengan pola yang muncul pada data baru. Jendela yang menunjukkan penyimpangan lebih besar akan memperoleh skor lebih tinggi dan dianggap lebih berpotensi mengandung anomali.

Arsitektur Anomaly Transformer menggunakan konfigurasi yang sama dengan dua model sebelumnya (2 *layer*, 4 *heads*, dimensi 64), dengan parameter tambahan untuk menghitung *prior-association* berdasarkan distribusi *Gaussian* yang disesuaikan dengan karakteristik data operasional migas.

3.4.4. Implementasi Model

Implementasi ketiga model berbasis Transformer dilakukan menggunakan *framework PyTorch* dengan menyesuaikan arsitektur terhadap karakteristik data operasional migas yang bersifat multivariat dan tidak berlabel. Seluruh model dilatih dengan *optimizer Adam* dan *learning rate* yang disesuaikan melalui proses hyperparameter tuning untuk memastikan konvergensi yang optimal pada masing-masing arsitektur.

Konfigurasi dasar yang digunakan untuk ketiga model yaitu, *input shape* (*batch_size*, 128, 4) , 2 *layer* Transformer, 4 *attention heads*, dimensi model 64, dan *dropout* yang disesuaikan melalui proses tuning. Perbedaan implementasi terletak pada mekanisme *loss function* dan cara perhitungan skor anomali. Transformer Autoencoder menggunakan *single MSE loss*, TranAD menggunakan kombinasi *dual reconstruction loss* dengan komponen *adversarial*, sedangkan Anomaly Transformer menggunakan *association discrepancy loss*.

Selama pelatihan, ketiga model mempelajari pola normal dari data *training* (30.393 *windows*), kemudian divalidasi menggunakan data *validation* (6.413 *windows*) untuk menentukan *epoch* terbaik. Setelah pelatihan selesai, model digunakan untuk menghasilkan skor anomali pada data *test* (6.414 *windows*) yang belum pernah dilihat sebelumnya. Skor anomali dari setiap model kemudian dibandingkan dengan *threshold* yang dipilih untuk menentukan apakah suatu window termasuk anomali atau normal.

Dengan menerapkan ketiga model ini secara konsisten menggunakan konfigurasi yang setara, penelitian dapat membandingkan tiga mekanisme pendeteksian : rekonstruksi tunggal (Transformer Autoencoder), rekonstruksi dua tahap (TranAD), dan analisis hubungan temporal (Anomaly Transformer). Hasil implementasi memungkinkan model menangkap berbagai jenis perubahan pola pada data operasional migas dengan karakteristik yang berbeda-beda.

3.5. Pelatihan Model

Proses pelatihan dilakukan agar ketiga model dapat mempelajari pola normal dari data operasional migas. Seluruh model dilatih menggunakan data training (30.393 *windows*) yang telah melalui tahap pra-pemrosesan, dengan data validation (6.413 *windows*) digunakan untuk memantau performa dan mencegah overfitting. Setiap model menerima input berukuran (*batch_size*, 128, 4) dan melakukan pembaruan bobot berdasarkan *loss function*.

Transformer Autoencoder meminimalkan MSE antara *input* dan rekonstruksi, TranAD meminimalkan kombinasi *dual reconstruction loss* dengan komponen *adversarial*, sedangkan Anomaly Transformer meminimalkan *association discrepancy loss*. Optimasi dilakukan menggunakan *Adam optimizer* dengan *learning rate*, *batch size*, dan jumlah epoch yang disesuaikan melalui proses hyperparameter tuning. Model dengan *validation loss* terendah disimpan sebagai *checkpoint* terbaik dan digunakan untuk tahap pengujian. Setelah pelatihan selesai, ketiga model menghasilkan skor anomali pada data test untuk dievaluasi dan dibandingkan performanya.


3.6. Pengujian Model & Perhitungan Skor

Setelah proses pelatihan selesai, ketiga model diuji menggunakan data pengujian tanpa pembaruan parameter, di mana setiap jendela data diproses untuk menghasilkan skor anomali berdasarkan bobot yang telah dipelajari. Transformer Autoencoder dan TranAD menentukan skor anomali dari selisih antara nilai asli dan hasil rekonstruksi, dengan TranAD menggunakan selisih pada rekonstruksi tahap kedua karena lebih sensitif terhadap perubahan kecil pada data, sedangkan Anomaly Transformer menghasilkan skor anomali berdasarkan perbedaan hubungan temporal dalam jendela waktu, bukan dari rekonstruksi sinyal. Seluruh skor anomali yang diperoleh kemudian dibandingkan dengan ambang batas (threshold) yang ditentukan dari distribusi skor data pelatihan, di mana jendela dengan skor di atas threshold dikategorikan sebagai anomali dan sisanya dianggap sebagai kondisi normal.

3.7. Penentuan Threshold

Setelah skor anomali diperoleh dari masing-masing model, selanjutnya adalah menentukan threshold untuk membedakan window normal dan anomali. Threshold ditetapkan berdasarkan distribusi skor data pelatihan sehingga batas anomali mengikuti pola yang dipelajari model, bukan ditentukan secara manual. Threshold yang dipilih pada kuantil ke-90 (P90) karena P90 memberikan keseimbangan antara sensitivitas dan stabilitas. Nilai

di bawah P90 menghasilkan terlalu banyak peringatan tidak relevan (*false positive*), sedangkan nilai di atas P90 berisiko melewatkan anomali yang relevan (*false negative*).



Gambar 3.2 Distribusi Skor Training dan *Threshold* P90 untuk Ketiga Model

Dari Gambar 3.2 terlihat bahwa distribusi skor training berbeda antarmodel. Transformer Autoencoder memiliki distribusi lebih lebar dengan threshold P90 sebesar 0.004938, menunjukkan variabilitas skor lebih tinggi. TranAD memiliki distribusi paling sempit dengan threshold P90 sebesar 0.002124, mengindikasikan sensitivitas tinggi terhadap perubahan kecil. Anomaly Transformer berada di tengah dengan threshold P90 sebesar 0.000994, menunjukkan stabilitas optimal antara deteksi sensitif dan konsisten.

Pendekatan ini memastikan proses deteksi berjalan secara konsisten pada seluruh model dengan threshold yang adaptif terhadap karakteristik distribusi skor masing-masing model.

3.8. Evaluasi Model dan Perbandingan Model

Evaluasi dilakukan untuk menilai kemampuan setiap model dalam mendeteksi anomali pada data operasional migas. Setelah *threshold* ditetapkan menggunakan kuantil ke-90 (P90) dari skor data pelatihan, skor anomali pada data validasi dan pengujian dibandingkan dengan nilai ambang tersebut untuk menentukan apakah suatu jendela tergolong normal atau anomali.

Karena dataset tidak memiliki label anomali, evaluasi dilakukan berdasarkan analisis kuantitatif dari beberapa aspek yaitu, distribusi skor anomali (rata-rata, deviasi standar, dan persentil P90–P99), jumlah window yang melewati *threshold* P90 sebagai ukuran sensitivitas, dan kestabilan skor pada segmen normal melalui metrik seperti *Coefficient of Variation* (CV) dan *Interquartile Range* (IQR).

Perbandingan antar model dilakukan dengan mempertimbangkan sensitivitas deteksi, kompleksitas arsitektur, dan efisiensi inferensi. Hasil analisis memberikan gambaran kekuatan dan kelemahan masing-masing model.

3.9. Spesifikasi Perangkat Keras

Eksperimen ini dijalankan menggunakan *Google Colab*. pra-pemrosesan, pelatihan model, pengujian, dan visualisasi data dieksekusi pada perangkat keras yang disediakan oleh platform tersebut. Konfigurasi perangkat keras yang digunakan dalam proses eksperimen adalah sebagai berikut :

- GPU : NVIDIA Tesla T4
- Memori GPU : 15 GB
- Kapasitas Penyimpanan (*Disk*) : 112.6 GB
- Lingkungan Eksekusi : *Google Colab (GPU runtime)*


BAB 4 HASIL PERCOBAAN DAN ANALISIS

Penelitian ini bertujuan untuk mengevaluasi kemampuan tiga model yaitu Transformer Autoencoder, TranAD, dan Anomaly Transformer untuk mengidentifikasi anomali pada data operasional migas. Untuk memastikan bahwa evaluasi mencerminkan kondisi operasional yang realistis, setiap model diuji dengan dataset yang dipisahkan secara temporal.

4.1. Hasil Pra-Pemrosesan Data

Dataset operasional migas periode 2017-2021 terdiri dari 304.964 baris yang setelah pembersihan nilai nol berkurang menjadi 303.960 baris, kemudian diagregasi per jam menggunakan median menjadi 43.601 baris.

Setelah agregasi, dataset dibagi secara temporal menjadi 70% training, 15% validation, dan 15% testing seperti ditunjukkan pada Gambar 4.1. Normalisasi StandardScaler diterapkan pada keempat fitur (*PRESSURE*, *TEMPERATURE*, *VOLUME_RATE*, *ENERGY_RATE*), diikuti sliding window (size 128, step 1) yang menghasilkan 30.393 window training, 6.413 window validation, dan 6.414 window testing.



Gambar 4.1 Visualisasi Pembagian Dataset *Train*, *Validation* dan *Test*

Normalisasi StandardScaler memastikan keempat fitur berada pada skala yang sebanding sehingga mekanisme self-attention pada model Transformer tidak bias terhadap fitur dengan range nilai lebih besar. Pembentukan sliding window menghasilkan struktur data berurutan yang konsisten, memungkinkan model mempelajari ketergantungan temporal secara efektif. Data yang telah melalui seluruh tahap pra-pemrosesan ini kemudian dimuat menggunakan DataLoader dengan batch size 256 dalam format tensor (256,

128, 4), sehingga siap digunakan untuk pelatihan, validasi, dan pengujian ketiga model Transformer.

4.2. Hasil *Tuning Hyperparameter*

Hasil konfigurasi *hyperparameter* optimal untuk ketiga model berdasarkan *validation loss*. Tabel 4.1 menunjukkan hasil *tuning* terbaik setelah melalui beberapa percobaan dengan variasi *learning rate*, *dropout*, jumlah *layer*, dan parameter khusus model.

Tabel 4.1 Konfigurasi Hyperparameter Terbaik untuk setiap model.


Model	layers	dropout	Learning rate	epoch	sigma	lamda KL	Best Vall_loss
Transformer Autoencoder	2	0.10	0.001	50	-	-	0.0039848
TranAD	2	0.05	0.001	50	-	-	0.007190
Anomaly Transformer	3	0.05	0.001	50	5.0	0.25	0.001947

Transformer Autoencoder menggunakan 2 layer dengan *dropout* 0.10 untuk mencegah *overfitting* pada pola rekonstruksi. TranAD memerlukan *dropout* lebih rendah (0.05) karena mekanisme *dual reconstruction* yang sensitif terhadap perubahan kecil, sehingga *dropout* besar dapat mengurangi kemampuan menangkap detail pola. Anomaly Transformer menggunakan 3 *layer* untuk kapasitas representasi lebih tinggi, dengan *dropout* 0.05 untuk menjaga stabilitas hubungan temporal. Parameter khusus *sigma* = 5.0 mengontrol rentang *prior-association*, sedangkan *lambda_KL* = 0.25 memberikan bobot proporsional pada *association discrepancy loss*.

Ketiga model mencapai konvergensi pada *epoch* 50 dengan *learning rate* 0.001 yang memberikan *balance* antara kecepatan *training* dan stabilitas *training*. Konfigurasi ini dipilih berdasarkan *validation loss* terendah dan stabilitas output selama validasi, dengan Anomaly Transformer mencapai *validation loss* terbaik di antara ketiga model.


4.3. Hasil Deteksi Anomali pada Data Uji

Hasil evaluasi performa ketiga model dalam mendeteksi anomali pada data test (6.414 *windows*) menggunakan *threshold* P90 yang dihitung dari distribusi skor training masing-masing model. Setiap model menghasilkan skor anomali berdasarkan mekanismenya: Transformer Autoencoder dari *reconstruction error*, TranAD dari *dual reconstruction discrepancy*, dan Anomaly Transformer dari *association discrepancy*. Window dengan skor di atas *threshold* P90 diklasifikasikan sebagai anomali.




Gambar 4.2 Deteksi Anomali pada model Transformer Autoencoder pada data test.

Transformer Autoencoder pada Gambar 4.2 menunjukkan deteksi yang lebih selektif, di mana anomali terdeteksi pada seluruh fitur, namun lebih sedikit pada periode awal. Model ini cenderung menandai anomali hanya ketika *reconstruction error* sangat tinggi, menghasilkan deteksi yang stabil namun kurang sensitif terhadap perubahan yang terjadi secara bertahap. Pada *PRESSURE* dan *TEMPERATURE*, deteksi anomali mulai muncul signifikan ketika nilai turun drastis di periode Juni-Agustus 2021.



Gambar 4.3 Deteksi Anomali pada model TranAD pada data test.

TranAD pada Gambar 4.3 mendeteksi anomali lebih agresif pada keempat fitur, terutama pada *VOLUME_RATE* dan *ENERGY_RATE* periode Juni-Agustus 2021. Mekanisme *dual reconstruction* membuat model sangat responsif terhadap perubahan kecil, terlihat dari deteksi anomali dengan frekuensi yang tinggi pada periode dengan fluktuasi tinggi. Model ini berhasil menangkap perubahan pola lebih awal dibanding Transformer Autoencoder, namun berpotensi menghasilkan alert lebih banyak pada fluktuasi normal.



Gambar 4.4 Deteksi Anomali pada model Anomaly Transformer pada data test.

Anomaly Transformer (Gambar 4.4) menunjukkan pola deteksi paling konsisten dengan fokus pada perubahan struktural hubungan antar fitur. Model ini mendeteksi anomali signifikan pada keempat fitur, terutama periode

Juni-Agustus 2021 ketika *PRESSURE*, *VOLUME_RATE*, dan *ENERGY_RATE* turun bersamaan. Berbeda dengan TranAD yang mendeteksi perubahan individual fitur, Anomaly Transformer lebih menekankan perubahan hubungan temporal antar fitur, menghasilkan deteksi yang lebih *robust* terhadap *noise* individual sensor.

4.4. Evaluasi dan Hasil Perbandingan Model

Hasil dari kinerja ketiga model berdasarkan sensitivitas deteksi, stabilitas skor, dan kompleksitas model. Tabel 4.2 menunjukkan hasil perbandingan kuantitatif pada data test.

Tabel 4.2 Hasil Perbandingan 3 Model pada data pengujian.

Metrik	Transformer Autoencoder	TranAD	Anomaly Transformer
Jumlah Window Anomali	268 (4.18%)	491 (7.66%)	567 (8.84%)
<i>Mean Score Normal</i>	0.002430	0.001289	0.000526
<i>Mean Score Anomaly</i>	0.009253	0.012884	0.003820
<i>Std Score Normal</i>	0.000924	0.000368	0.000105
<i>Std Score Anomaly</i>	0.004837	0.016841	0.003826
Waktu Inferensi	0.079 ms/window	0.121 ms/window	0.066 ms/window

Berdasarkan Tabel 4.2, Transformer Autoencoder mendeteksi anomali paling sedikit (268 window, 4.18%) dengan *mean score* normal tertinggi (0.002430), menunjukkan baseline skor normal yang lebih tinggi sehingga lebih sedikit window yang melampaui batas P90. TranAD mendeteksi jumlah anomali lebih banyak (491 window, 7.66%) dan menghasilkan pemisahan yang kuat antara kondisi normal dan anomali (*mean score anomaly* 0.012884 dan *mean score normal* 0.001289), menunjukkan kemampuan pembedaan yang baik. Anomaly Transformer mendeteksi anomali paling banyak (567 window, 8.84%) dengan *mean score* normal terendah (0.000526), mengindikasikan skor yang paling stabil pada segmen normal.

Anomaly Transformer memiliki stabilitas tertinggi dengan standar deviasi (*std*) *score normal* terendah (0.000105), menunjukkan konsistensi skor pada data normal. Transformer Autoencoder memiliki *std score normal* tertinggi (0.000924), yang mengindikasikan variabilitas skor normal lebih besar dan potensi deteksi yang kurang konsisten. Pada segmen anomali, TranAD memiliki *std score anomaly* tertinggi (0.016841) karena mekanisme *dual reconstruction* yang sangat responsif terhadap perubahan, sedangkan Anomaly Transformer menunjukkan variabilitas yang lebih moderat (0.003826).

Anomaly Transformer memiliki waktu inferensi tercepat (0.066 ms/window) meskipun menggunakan arsitektur yang lebih kompleks, menunjukkan efisiensi implementasi yang baik. Transformer Autoencoder berada di tengah (0.079 ms/window) dengan arsitektur paling sederhana, sedangkan TranAD memiliki waktu inferensi terlama (0.121 ms/window) karena mekanisme *dual reconstruction* yang memerlukan dua proses rekonstruksi pada setiap *forward pass*.

Berdasarkan evaluasi kuantitatif, terdapat trade-off yang jelas antara sensitivitas, stabilitas, dan efisiensi. Transformer Autoencoder cocok untuk sistem yang cenderung konservatif dengan jumlah deteksi anomali rendah, namun berpotensi melewatkan anomali ringan. TranAD memberikan pemisahan skor yang kuat untuk mendeteksi anomali signifikan dengan konsekuensi waktu inferensi lebih lama dan variabilitas skor anomali yang tinggi. Anomaly Transformer menawarkan keseimbangan optimal dengan stabilitas tertinggi (*std score normal* 0.000105), efisiensi terbaik (0.066 ms/window), dan jumlah deteksi paling banyak, menjadikannya pilihan yang sesuai untuk sistem pemantauan operasional migas yang memerlukan deteksi konsisten dan efisien.

BAB 5 KESIMPULAN DAN SARAN

5.1. Kesimpulan

Penelitian ini memberikan kontribusi dalam mengevaluasi dan membandingkan tiga arsitektur Transformer yaitu Transformer Autoencoder, TranAD, Anomaly Transformer, dalam mendeteksi anomali pada data operasional migas nyata yang bersifat multivariat dan tidak berlabel. Melalui analisis kuantitatif dan distribusi skor anomali, penelitian ini menunjukkan bahwa Transformer Autoencoder sebagai model baseline mampu mempelajari pola normal data melalui mekanisme rekonstruksi, namun cenderung menghasilkan variabilitas skor yang lebih tinggi pada segmen normal sehingga berpotensi memunculkan peringatan tidak relevan.

Analisis karakteristik skor anomali menunjukkan bahwa perbedaan mekanisme perhitungan skor pada tiap model menghasilkan perilaku deteksi yang berbeda. Transformer Autoencoder menghasilkan skor anomali berbasis *error* rekonstruksi (MSE) antara input dan output, sehingga perubahan nilai sinyal yang tidak dapat direkonstruksi dengan baik akan meningkatkan skor. TranAD juga berbasis rekonstruksi, namun menggunakan dua tahap rekonstruksi (*dual reconstruction*), sehingga skor diturunkan dari perbedaan dua *error* rekonstruksi; mekanisme ini membuat model lebih peka terhadap perubahan kecil dan menghasilkan pemisahan skor yang jelas, dengan nilai rata-rata skor anomali sebesar 0.012884 dan skor normal sebesar 0.001289. Berbeda dari dua model sebelumnya, Anomaly Transformer menghitung skor berdasarkan *association discrepancy*, yaitu ketidaksesuaian hubungan temporal antara *series-association* dan *prior-association*, sehingga skor lebih merefleksikan perubahan struktur keterkaitan antar fitur dan menghasilkan kestabilan yang lebih baik pada segmen normal.

Berdasarkan evaluasi kuantitatif terhadap aspek sensitivitas deteksi, stabilitas skor, dan efisiensi komputasi, Anomaly Transformer merupakan

model terbaik dalam penelitian ini. Model ini menunjukkan stabilitas tertinggi dengan standar deviasi skor normal terendah sebesar 0.000105, jumlah deteksi anomali paling tinggi yaitu 567 window (8.84%), serta waktu inferensi tercepat sebesar 0.066 ms per window. Dengan pemisahan skor yang konsisten, stabilitas tinggi pada data normal, dan efisiensi komputasi yang baik, Anomaly Transformer dinilai paling sesuai untuk diterapkan pada sistem pemantauan operasional migas yang membutuhkan deteksi anomali yang konsisten, efisien, dan minim peringatan tidak relevan.

5.2. Saran

Dalam saran pengembangan, sistem deteksi anomali dalam penelitian selanjutnya harus dirancang secara lebih terarah agar tujuan pemantauan operasional migas dapat dicapai dengan lebih efisien. Fokus pengembangan harus mencakup identifikasi masalah yang lebih rinci, penyesuaian dengan teknologi saat ini, dan perbaikan model dan eksperimen yang gagal. beberapa saran untuk penelitian selanjutnya adalah sebagai berikut.

Pertama, melakukan validasi hasil deteksi dengan label anomali aktual dari catatan operasional atau laporan insiden untuk menghitung metrik precision, recall, dan F1-score secara objektif sehingga dapat mengukur akurasi deteksi secara kuantitatif.

Kedua, menguji metode penentuan threshold adaptif atau dinamis yang dapat menyesuaikan dengan perubahan kondisi operasional untuk mengurangi false positive pada periode transisi atau perubahan regime operasional.

Ketiga, mengevaluasi performa model pada dataset operasional migas dari platform berbeda untuk menguji model pada variasi karakteristik, tekanan, dan kondisi operasional yang lebih beragam.

DAFTAR PUSTAKA

- [1] European Gas Pipeline Incident Data Group, “11th Report of the European Gas Pipeline Incident Data Group,” 2020. [Daring]. Tersedia pada: <https://www.egig.eu>
- [2] D.-T. Nguyen, T.-K. Nguyen, Z. Ahmad, dan J.-M. Kim, “A reliable pipeline leak detection method using acoustic emission with time difference of arrival and Kolmogorov–Smirnov test,” *Sensors*, vol. 23, no. 23, p. 9296, 2023.
- [3] S. B. Wankhede, “Anomaly detection using machine learning techniques,” dalam *2019 IEEE 5th International Conference on Internet of Things: Smart Innovation and Usages (I2CT)*, 2019.
- [4] A. Vaswani dkk., “Attention is All You Need,” dalam *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, hlm. 5998–6008.
- [5] S. Tuli dkk., “TranAD: Deep transformer networks for anomaly detection in multivariate time series,” *arXiv preprint*, 2022.
- [6] J. Xu, H. Wu, J. Wang, dan M. Long, “Anomaly Transformer: Time series anomaly detection with association discrepancy,” *arXiv preprint*, 2021.
- [7] I. M. N. Oliveira dkk., “Advancing anomaly detection in oil production wells with TranAD : A Deep Transformer Network Approach,” dalam *Proceedings of CILAMCE 2024*, 2024.
- [8] S. S. Aljameel dkk., “An anomaly detection model for oil and gas pipelines using machine learning,” *Computation*, vol. 10, no. 8, hlm. 138, 2022.
- [9] J. Audibert, P. Michiardi, F. Guyard, dan M. Marti, “USAD: Unsupervised anomaly detection on multivariate time series,” *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2020.
- [10] L. Xu dkk., “GAN-AD: Transformer-based GAN for anomaly detection of time series data,” *Applied Sciences*, vol. 12, no. 16, hlm. 8085, 2022.
- [11] J. Li, X. Wang, Q. Sun, dkk., “Anomaly-PTG: A time series data–anomaly-detection transformer framework in multiple scenarios,” *Electronics (Basel)*, vol. 11, no. 7, hlm. 1066, 2022.
- [12] G. Pang, C. Shen, L. Cao, dan A. van den Hengel, “Deep learning for anomaly detection: A review,” *ACM Comput Surv*, vol. 54, no. 2, hlm. 1–38, 2020.
- [13] Q. Wen dkk., “Transformers in time series: A survey,” *arXiv preprint*, 2022.

- [14] F. Wang dkk., “A survey of deep anomaly detection in multivariate time series: Taxonomy, applications, and directions,” *Sensors*, vol. 25, no. 1, hlm. 190, 2025.
- [15] A. F. Ihsan dan W. Astuti, “Deep learning-based anomaly detection on natural gas pipeline operational data,” dalam *2022 2nd International Conference on Informatics and Computational Thinking in Asia (ICICyTA)*, 2022, hlm. 228–233.